Projeto1

Thiago Barral

1/23/2020

Carregando os pacotes necessários

```
library(readr)
library(ggplot2)
library(dplyr)
##
## Attaching package: 'dplyr'
## The following objects are masked from 'package:stats':
##
##
       filter, lag
## The following objects are masked from 'package:base':
##
       intersect, setdiff, setequal, union
##
library(gplots)
##
## Attaching package: 'gplots'
## The following object is masked from 'package:stats':
##
##
       lowess
library(lubridate)
##
## Attaching package: 'lubridate'
## The following object is masked from 'package:base':
##
##
       date
library(DMwR)
## Loading required package: lattice
## Loading required package: grid
## Registered S3 method overwritten by 'xts':
##
     method
                from
##
     as.zoo.xts zoo
## Registered S3 method overwritten by 'quantmod':
##
##
     as.zoo.data.frame zoo
```

```
library(e1071)
library(pROC)
## Type 'citation("pROC")' for a citation.
##
## Attaching package: 'pROC'
## The following objects are masked from 'package:stats':
##
##
       cov, smooth, var
library(caTools)
library(rmarkdown)
library(knitr)
library(tinytex)
Carregando os dados
Carregando os dados de trabalho. Fazendo uma análise inicial dos dados.
train_sample <- read_csv('train_sample.csv', col_names = TRUE)</pre>
## Parsed with column specification:
## cols(
##
    ip = col_double(),
    app = col_double(),
    device = col_double(),
##
##
    os = col_double(),
##
    channel = col_double(),
    click_time = col_datetime(format = ""),
     attributed_time = col_datetime(format = ""),
##
     is_attributed = col_double()
## )
str(train_sample)
## Classes 'spec_tbl_df', 'tbl_df', 'tbl' and 'data.frame': 100000 obs. of 8 variables:
## $ ip
                    : num 87540 105560 101424 94584 68413 ...
                    : num 12 25 12 13 12 3 1 9 2 3 ...
## $ app
## $ device
                   : num 1 1 1 1 1 1 1 1 2 1 ...
## $ os
                    : num 13 17 19 13 1 17 17 25 22 19 ...
## $ channel
                   : num 497 259 212 477 178 115 135 442 364 135 ...
## $ click_time
                   : POSIXct, format: "2017-11-07 09:30:38" "2017-11-07 13:40:27" ...
## $ attributed_time: POSIXct, format: NA NA ...
## $ is_attributed : num 0 0 0 0 0 0 0 0 0 ...
## - attr(*, "spec")=
##
    .. cols(
##
        ip = col_double(),
##
    .. app = col_double(),
##
    .. device = col_double(),
     .. os = col_double(),
##
     .. channel = col_double(),
##
    .. click_time = col_datetime(format = ""),
##
##
    .. attributed_time = col_datetime(format = ""),
    .. is_attributed = col_double()
```

##

..)

```
summary(train_sample)
##
                                            device
          ip
                           app
                                                                  os
##
    Min.
                      Min.
                                1.00
                                        Min.
                                                    0.00
                                                           Min.
                                                                   : 0.00
##
    1st Qu.: 40552
                      1st Qu.:
                                3.00
                                        1st Qu.:
                                                    1.00
                                                           1st Qu.: 13.00
##
    Median: 79827
                      Median : 12.00
                                        Median:
                                                    1.00
                                                           Median: 18.00
##
    Mean
           : 91256
                      Mean
                             : 12.05
                                        Mean
                                                   21.77
                                                                   : 22.82
                                                           Mean
##
    3rd Qu.:118252
                      3rd Qu.: 15.00
                                        3rd Qu.:
                                                    1.00
                                                           3rd Qu.: 19.00
           :364757
                             :551.00
                                                :3867.00
                                                                   :866.00
##
    Max.
                                        Max.
                                                           Max.
                      Max.
##
##
       channel
                       click_time
                                                     attributed_time
##
   Min.
                             :2017-11-06 16:00:00
                                                     Min.
                                                            :2017-11-06 17:19:04
           : 3.0
    1st Qu.:145.0
                     1st Qu.:2017-11-07 11:34:09
                                                     1st Qu.:2017-11-07 11:50:27
##
    Median :258.0
                     Median :2017-11-08 07:07:50
                                                     Median :2017-11-08 06:43:39
##
##
    Mean
           :268.8
                             :2017-11-08 06:29:52
                                                            :2017-11-08 07:04:12
                                                     Mean
    3rd Qu.:379.0
                     3rd Qu.:2017-11-09 02:06:01
                                                     3rd Qu.:2017-11-09 01:42:52
##
    Max.
           :498.0
                     Max.
                            :2017-11-09 15:59:51
                                                            :2017-11-09 15:28:15
                                                     Max.
                                                     NA's
                                                            :99773
##
##
    is_attributed
##
   Min.
           :0.00000
##
    1st Qu.:0.00000
##
   Median :0.00000
##
   Mean
           :0.00227
##
    3rd Qu.:0.00000
##
    Max.
           :1.00000
##
table(train_sample$is_attributed)
##
##
       0
             1
## 99773
           227
prop.table(table(train_sample$is_attributed))
##
##
         0
## 0.99773 0.00227
```

Limpando os dados

A variável 'os' representa a mesma coisa que a coluna device logo será retirada. A variável 'ip' serve simplesmente para identificação então não influenciará no estudo. A variável 'attributed_time' representa o horário no qual o usuário fez o download, então também será retirado pois não é representativa, visto que já temos a variável 'click_time'.

```
train_sample$os <- NULL
train_sample$attributed_time <- NULL
train_sample$ip <- NULL</pre>
```

Mudando a variável do tempo

A variável 'click_time' tem informação da data e da hora exata que o usuário entrou no site, porém eu acretido que somente a hora seja um fator de relevância, visto que é algo que não e afetado pela sazonalidade e a exatidão de minutos e segundos não se faz necessária.


```
train_sample$hora <- hour(train_sample$click_time)
train_sample$click_time <- NULL</pre>
```

Gráficos


Análise visual para entender o comportamento das variáveis.


Transformando variáveis

```
ggplot(train_sample, aes(x = channel, y = is_attributed)) +
geom_bar(stat = 'identity')
```




```
ggplot(train_sample, aes(x = device, y = is_attributed)) +
geom_bar(stat = 'identity')
```







Warning: Ignoring unknown parameters: binwidth, bins, pad




 $\mbox{\tt \#\#}$ Warning: Ignoring unknown parameters: binwidth, bins, pad



Warning: Ignoring unknown parameters: binwidth, bins, pad



Warning: Ignoring unknown parameters: binwidth, bins, pad



As variáveis 'is_attributed', 'app', 'device', 'channel' e 'hora' estão categorizadas como numéricas porém elas não representão números e sim classes, então transforei as 5 em factor.

```
train_sample$is_attributed <- as.factor(train_sample$is_attributed)
train_sample$app <- as.factor(train_sample$app)
train_sample$device <- as.factor(train_sample$device)
train_sample$channel <- as.factor(train_sample$channel)
train_sample$hora <- as.factor(train_sample$hora)</pre>
```

Dividindo dados em treino e teste

69841

159

Realizei a divisão de 70% dos dados em dados de treino e os demais 30% em dados de teste.

```
train_sample$spl <- sample.split(train_sample$is_attributed, SplitRatio = 0.7)
table(train_sample$spl)</pre>
```

```
##
## FALSE TRUE
## 30000 70000

treino_train <- dplyr::filter(train_sample, train_sample$spl == TRUE)
teste_train <- dplyr::filter(train_sample, train_sample$spl == FALSE)
table(treino_train$is_attributed)

##
##
##
0 1</pre>
```

Balanceamento da variável alvo

Como os dados estão desbalenceados, ou seja, há muito mais dados referentes aos usuários que não baixaram o app, há a necessidade de se realizar o balanceamento para que não haja tendência no modelo.

```
train_sample_smote <- SMOTE(is_attributed~., as.data.frame(treino_train), perc.over = 5000, k = 5, perc
table(train_sample_smote$is_attributed)

##
## 0 1
## 7950 8109

respostas_train_teste <- teste_train$is_attributed
teste_train$is_attributed <- NULL
teste_train$spl <- NULL</pre>
```

Previsão

Utilizei o modelo Naive Bayes para prever quais os usuários são fradulentos.

```
nb <- naiveBayes(is_attributed~., treino_train)
prev <- predict(nb, teste_train)</pre>
```

Avaliação

O método utilizado para avaliação e o area under the curve (AUC).

```
roc(response = as.numeric(respostas_train_teste), predictor = as.numeric(prev), auc = TRUE)

## Setting levels: control = 1, case = 2

## Setting direction: controls < cases

##

## Call:

## roc.default(response = as.numeric(respostas_train_teste), predictor = as.numeric(prev), auc = TRUE)

##

## Data: as.numeric(prev) in 29932 controls (as.numeric(respostas_train_teste) 1) < 68 cases (as.numeric##

## Area under the curve: 0.937</pre>
```